

M-IR + MVM：面向大语言模型生成的 紧凑硬件控制表示与有界执行框架

马英杰

北华航天工业学院

摘要

大语言模型生成的控制程序在资源受限 MCU 上缺乏既紧凑又可安全执行的表示。本文提出 M-IR + M-bytecode + MVM 两层框架：M-IR 面向 LLM 生成（输出 token 显著低于 JSON，以更长的 system prompt 为代价），编译为传输紧凑的 M-bytecode（压缩率 9.8x vs zlib-JSON, 9.6x vs CBOR），在 MVM 上以 capability gating 和 step-limit 实现运行时有界执行（bounded execution）。在确定性解码模式（temperature=0）下，113 个确定性任务的 M-IR → M-bytecode 链路含 repair 全线通过率达 1.000，repair loop 的 success@1 为 0.982；在 96 个闭环任务上，通过 prompt 工程消除 retry/repeat 语义混淆后 task_success_rate 达 0.948。在非零温度采样模式下成功率显著下降（0.6 时 0.909±0.289，1.0 时 0.847±0.361），表明当前框架的可靠性依赖于确定性解码。有界执行实验验证了 UABR=1.000 的异常阻断能力。实验结果表明该框架在确定性控制与闭环语义子集上均具有可行性，但在采样模式下的鲁棒性仍需进一步研究。

关键词：大语言模型；硬件控制；中间表示；字节码；虚拟机；嵌入式系统

1 引言

1.1 背景与动机

将大语言模型生成的控制程序部署到资源受限微控制器（MCU）上，是 AI 驱动硬件控制的核心落地挑战。已有工作证明 LLM 生成控制逻辑的可行性：Code-as-Policies [1] 使用 LLM 生成高层 Python policy 来控制机器人臂，RT-2 [2] 将视觉语言模型直接输出为机器人动作序列。然而，当目标设备从桌面级机器人变为 ESP8266 等资源受限 MCU 时，问题的约束条件发生了本质变化。考虑一个具体场景：用户对系统说“打开水泵并读取水位传感器”，系统需要将这条自然语言指令转化为可在 MCU 上安全执行的控制程序。这一过程至少面临四类约束：文本表示是否适合 LLM 稳定生成，编译后程序是否足够紧凑以便低带宽链路传输，设备端执行是否有界且可审计，以及当模型输出错误程序时系统能否阻断风险并回结结构化错误。

1.2 现有方法的局限

现有方案难以同时满足上述约束。JSON 接口在 IoT 场景中广泛使用，易于生成且生态成熟，但文本冗余高，一条简单控制指令的 JSON 编码可达百字节量级，不利于带宽受限的 MCU 链路。Python 等高层代码表达力强，但端侧执行需要完整解释器，资源代价高，且缺乏形式化的执行边界约束。WASM/WAMR 等通用字节码运行时和 grammar-constrained decoding 等生成约束技术各自解决了问题的一个侧面——前者关注沙箱与可移植性，后者关注输出格式合法性——但均未将 LLM 的生成成本、编译紧凑性、端侧有界执行和闭环反馈作为一个统一问题处理。

1.3 问题定义与目标

本文探索能否设计一种既适合 LLM 生成、又能编译为紧凑字节码并在 MCU 上安全执行的控制表示。具体而言，系统需同时满足六项设计目标：token-efficient（生成紧凑）、compact（传输紧凑）、deterministic-to-compile

(编译确定)、`statically-checkable`(静态可验证)、`bounded-to-execute`(执行有界)和 `auditable-on-fault`(故障可审计)，详见 §2.3。

为此提出两层框架 M-IR + M-bytecode + MVM，将”生成友好”和”执行友好”分层优化。**核心思路**：将控制表示拆分为两层——M-IR（面向 LLM 的文本 DSL）负责生成友好，M-bytecode（面向 MCU 的紧凑字节码）负责执行友好，二者通过确定性 compiler 连接；生成与执行不再被强行揉进一个表示，而是各自独立优化。

注：M-IR 的输出紧凑性以更长的 system prompt 为代价，在 prompt 可缓存的场景下总成本优势才会显现（详见 §8.9）。这一两层设计体现了一种更广泛的设计思路：**LLM 与受限环境交互的分层解耦**——上层面向模型的自然表达习惯（生成友好），下层面向执行环境的物理约束（执行友好），二者通过确定性编译连接。§2 给出形式化的问题定义与评价指标。

1.4 关键挑战

实现上述目标面临以下技术挑战：

1. **生成-执行鸿沟**：LLM 擅长结构化文本，但紧凑字节码对模型而言不可读、不可调试；同时，IR 到字节码的 lowering 必须确定且无歧义，任何 ambiguity 都会导致不可预测的端侧行为。这两层之间的张力——既要生成友好又要执行紧凑、既要灵活表达又要确定性编译——是框架设计的核心矛盾。
2. **端侧有界执行**：AI 生成的程序本质上不可信，需要在 MCU 上通过 capability 约束、步数限制和结构验证确保执行不会越权或死循环。
3. **闭环反馈与修复**：当执行失败时，系统需要将结构化错误信息回传给 LLM 以触发修复，而非仅返回不可解析的故障码。

1.5 解决方案概述

本文采用两层设计以应对上述挑战：

1. **M-IR**（面向挑战 1 的生成侧）：面向 LLM 输出的结构化中间表示，强调 token 效率、可编译性和可调试性，支持 capability 声明、读回验证与重试语义。
2. **M-bytecode**（面向挑战 1 的执行侧）：由 compiler 确定性 lowering 生成的紧凑字节码，采用 varint 编码与栈式执行模型，体积显著低于 JSON/CBOR/MessagePack。
3. **MVM 与静态验证器**（面向挑战 2）：在 MCU 上提供 capability gating、step-limit、结构验证与 fault audit，确保有界执行。
4. **生成链路与 repair loop**（面向挑战 3）：打通 LLM → M-IR → bytecode → verify → execute → feedback → repair 的完整路径，支持结构化错误回传与自动修复。

”生成友好”和”执行友好”不再被强行揉成一个层次，而是分别优化。以贯穿全文的 running example 为例：用户输入”打开水泵并读取水位传感器”，LLM 输出 6 行 M-IR，compiler 将其 lowering 为 12 字节 M-bytecode，在 ESP8266 上以 6 steps 完成执行（完整链路见 §6.1）。

1.6 贡献

本文的贡献依次对应后续章节：

1. 提出两层控制表示框架 M-IR 与 M-bytecode，显式支持 capability 声明、读回验证与重试语义，将工作定位为 LLM 与受限环境交互的分层解耦设计方法（第4章）。

2. 实现 MVM 与静态验证器，在 ESP8266 上提供 capability、step-limit、fault audit 与闭环读回支持（第5章）。
3. 实现 LLM $\rightarrow$ M-IR $\rightarrow$ bytecode 生成管道与 repair loop，在 113 个确定性任务上达到 1.000 全线通过率（repair success@1=0.982），在闭环子集上识别出核心瓶颈（`retry` 语义混淆占闭环失败的 77.3%）并给出系统错误分析（第7-8章）。

1.7 论文结构

第2章定义问题与设计目标；第3章介绍相关工作；第4章介绍 M-IR 与 M-bytecode 设计；第5章介绍 MVM 与 static verifier（静态验证器）；第6章描述生成链路与 repair loop；第7章给出实验设计；第8章汇报结果与分析；第9章讨论局限与扩展；第10章总结全文。

术语约定与词汇表：正文统一使用 M-IR、M-bytecode（带连字符）；代码/错误码中 MIR_ 前缀为命名规范。‘output-token-efficient’ = 输出侧 token 紧凑（LLM 生成的 M-IR 文本 token 数少）；注意 M-IR 的总 token 成本（system prompt + output）高于 JSON 等更简短的 prompt 格式，其 token 效率优势仅在 system prompt 被缓存复用后以增量成本（即仅计 output token）体现（详见 §8.9）。‘compact’ / ‘byte-compact’ = 传输紧凑（编译后字节少）。本文所称“安全”除特别说明外均特指运行时有界执行（bounded execution），完整威胁模型见 §2.6。

核心术语： M-IR（LLM 生成友好的文本中间表示，§4）| M-bytecode（MVM 执行的紧凑 varint 字节码）| MVM（Micro Virtual Machine，MCU 上的受限栈式 VM，§5）| Lowering（M-IR $\rightarrow$ M-bytecode 的确定性编译）| Capability Gating（基于 M-IR 声明的设备能力门控）| Step-limit（执行步数上限，保证终止）| Fault Audit（运行时故障码记录与回传）| UABR（未授权访问阻断率）| SCR（安全收敛率，§2.4）| Repair Loop（编译/验证失败后的 LLM 修复循环，§6）。

2 问题定义与设计目标

2.1 目标场景

本文面向一类离散或中低频控制任务：上位机或云端 AI 根据自然语言任务描述和设备白名单生成控制程序，端侧 MCU 接收该程序并执行，同时返回故障码、读回值和执行状态。

本文当前不覆盖：

1. 高频硬实时闭环控制；
2. 大规模视觉输入到动作的端到端学习；
3. 通用脚本运行时生态。

2.2 三类成本

本文关注三类成本：

1. **生成成本：** LLM 输出控制表示所需 token；
2. **传输成本：** 编译后程序长度与链路体积；
3. **执行成本：** 设备端解析、执行与闭环读回的时延与资源开销。




图 1: 系统总览图。上半部分为前端生成链路 (Natural Language → LLM → M-IR → Compiler → Verifier → M-bytecode)，下半部分为后端执行链路 (Transmission → MVM → Hardware I/O → Feedback → Repair Loop)，运行时保护机制 (Capability Gating、Step Limit、Fault Audit、Closed-loop Verify) 在运行时约束 MVM 执行。

2.3 设计目标

系统目标为：

1. token-efficient
2. compact
3. deterministic-to-compile
4. statically-checkable
5. bounded-to-execute
6. auditable-on-fault

2.4 指标映射

表 1 给出研究问题与评价指标映射。

2.5 核心指标定义

本文使用以下核心指标，此处给出形式化定义以确保可复现性。

表 1: 研究问题与评价指标映射

研究问题	评价指标
RQ1	token 数、bytecode 长度、RTT、执行时延
RQ2	IR 合法率、compile pass rate、verify pass rate、execution success rate、success@k
RQ3	UABR、fault 分布、SAFE 分流、SCR、P95 RTT

压缩率: 设 $B_M(t)$ 和 $B_{JSON}(t)$ 分别为任务 t 的 M-bytecode 与 JSON payload 字节数, 则平均压缩率与加权压缩率定义为:

$$R_{AVG} = \frac{1}{|T|} \sum_{t \in T} \frac{B_{JSON}(t)}{B_M(t)}, \quad R_{WEIGHTED} = \frac{\sum_{t \in T} B_{JSON}(t)}{\sum_{t \in T} B_M(t)} \quad (1)$$

任务成功率 (Task Success Rate): 设 T 为任务集, $\mathbf{1}[\cdot]$ 为指示函数, 则:

$$TSR = \frac{1}{|T|} \sum_{t \in T} \mathbf{1}[\text{task } t \text{ passes all stages}] \quad (2)$$

其 95% Wilson 置信区间按标准二项比例方法计算。

未授权访问阻断率 (UABR): 在安全实验中, 设 N_{blocked} 为被 capability gating 或 validator 阻断的未授权请求数, N_{total} 为总未授权请求数, 则 $UABR = N_{\text{blocked}}/N_{\text{total}}$ 。

安全收敛率 (SCR): 在闭环实验中, 经过 k 轮 retry 后达到目标状态的任务比例。

Repair success@k: 在 repair loop 中, 第 k 轮修复后首次成功的任务数占总任务数的比例。

2.6 威胁模型

安全范围说明: 本文所称“安全”特指运行时有界执行 (capability 约束、step-limit、结构验证、故障审计), 不涵盖链路认证、加密传输、供应链安全或物理对抗等更广泛的安全议题。

本文默认:

1. LLM 输出不可信;
2. 外部输入可能被构造、篡改或重放;
3. validator、执行器和基础 I/O 驱动是当前可信计算基;
4. 链路认证、加密、供应链攻击与物理对抗不在本文验证范围内。

本文所验证的“安全”边界仅限于: **运行时有界执行**, 即通过 capability gating、step-limit、静态验证和 fault audit 确保 MCU 执行的程序不会越权、不会无限循环、不会产生未审计的故障。这与更广泛意义上的“系统安全” (涵盖认证、加密、防篡改等) 有明确区分。

3 相关工作

3.1 资源受限 VM 与字节码执行

TinyVM [4] 面向嵌入式 C 子集提供轻量字节码解释器, Darjeeling [5] 为 FPGA 上的软处理器设计了 Java 子集 VM, AtomVM [6] 在 ESP32 上实现 Erlang/BEAM 子集。WASM/WAMR [3] 提供跨平台字节码沙箱, eBPF 在 Linux 内核中实现受限程序的有界执行。这些系统主要强调通用脚本执行、可移植性、沙箱隔离或轻量部署。

本文与它们的差异在于：本文把 **LLM 生成成本** 明确纳入设计目标，而不是只做“又一个轻量 VM”。M-IR 的语法设计以 LLM 的 token 效率为出发点，M-bytecode 的编码方案以传输体积为优化目标，这是现有嵌入式 VM 工作未涉及的维度。

从编译器 IR 设计的视角看，M-IR 的设计借鉴了经典 IR 的分层思想：类似 LLVM IR 在高层语言与机器码之间提供抽象层，或 WASM 文本格式（WAT）在可读性与紧凑二进制（WASM）之间建立桥梁 [15,16]。M-IR 的独特之处在于其“面向 LLM 生成”的设计约束——IR 设计通常以编译器分析和优化为目标，而 M-IR 的语句集（set/read/wait/retry 等）直接映射到控制任务的领域语义，牺牲了一般性以换取生成稳定性。关于 step-limit 和 capability gating 机制，本文的设计与实时 Java 安全子集（如 SCJ [17]）和沙箱指令计数（如 Google Native Client [18]）共享“有界执行”的核心思想，但在 MCU 级实现上做了显著简化——MVM 以约 500 行 C++ 代码实现完整的栈机 + 22 种 fault 码 + 串口协议，无需操作系统支持。

值得进一步澄清的是：为什么 **WASM/WAMR 或 eBPF 不能简单适配以解决本文的问题**？WASM 的文本格式（WAT）使用 S-expression 语法，LLM 对其的熟悉度远低于类 C 赋值语句，且在 MCU 上运行完整的 WASM 解释器（即使是最小配置的 WAMR）需要数十 KB 的 RAM 开销，远超 MVM 的约 2KB 栈空间。eBPF 的指令集为内核级数据平面优化，缺少 MCU 硬件控制所需的 GPIO 读写、模拟量采样和毫秒级等待原语。此外，两者均不提供 M-IR 的 `require cap(...)` 设备能力声明和 `readback/retry` 闭环语义的原生支持——这些语义需要在应用层额外编码，破坏了端到端的紧凑性。

3.2 LLM 代码生成与机器人控制

Code-as-Policies [1] 使用 LLM 将自然语言指令解析为 Python 代码片段，通过程序合成控制机器人臂执行抓取、搬运等任务。其优势在于 Python 的表达力和生态，但 Python 解释器的资源需求使其难以部署在 MCU 上。RT-2 [2] 将视觉语言模型直接微调为动作输出模型，实现了端到端的机器人控制，但其设计面向桌面级机器人平台，不涉及资源受限设备的执行约束。

本文关注更窄但更工程化的问题：如何生成适合 MCU 落地、可验证、可编译的控制表示。与 Code-as-Policies 相比，本文将执行层从 Python 下降到字节码；与 RT-2 相比，本文保留了显式的 IR 编译路径而非端到端映射。

3.3 IoT 控制接口

JSON / text command 在 IoT 场景中广泛存在，MQTT、CoAP 等协议的 payload 通常采用 JSON 编码。其优点是简单与生态成熟；缺点是冗余高，一条简单控制指令的 JSON 编码可达百字节量级。CBOR 和 MessagePack 作为二进制替代方案，能减少约 30–50% 的体积，但仍保留了通用序列化格式的结构开销。需说明的是，CBOR 和 MessagePack 为二进制序列化格式，其设计目标并非供 LLM 直接生成；让 LLM 输出二进制 payload 面临与 Direct Hex 基线 (§7.3) 相同的根本困难——模型无法稳定生成二进制编码，且错误无法被结构化解析与修复。因此，本文的比较聚焦于编译后体积（表 3），即 M-IR 经确定性 compiler 后的字节码与同等语义的 JSON/CBOR/MessagePack payload 的对比。现有方案均未同时优化生成成本、传输体积和端侧执行边界。

3.4 本文定位

本文位于三类工作交叉处：

1. 借用 LLM 的生成能力；
2. 借用嵌入式 VM 的有界执行思想；
3. 借用 IoT 控制任务的设备语义与部署场景。

3.5 结构化生成与约束解码

近年来,结构化生成技术(如 JSON mode、grammar-constrained decoding [12])已被广泛用于强制 LLM 输出符合特定格式。这类方法的核心思路是在解码阶段施加语法约束,使输出必定满足预定义的 schema。

本文与这类工作的关键差异在于:约束解码解决的是输出格式合法性问题,而 M-IR 还额外解决了以下问题:

1. **可编译性:** M-IR 不仅是合法文本,还能被确定性地 lowering 为紧凑字节码,这是 JSON Schema 约束无法保证的;
2. **设备能力声明:** M-IR 的 `require cap(...)` 语法将设备能力约束嵌入表示层,而非依赖外部校验;
3. **闭环语义集成:** `readback/retry` 等闭环操作被编译为字节码级控制流,而非留在文本层由外部解释;
4. **端侧有界执行:** M-bytecode 通过 `capability gating` 和 `step-limit` 在 MCU 上提供运行时安全保障,这是输出格式约束完全无法覆盖的。

因此,即使使用 grammar-constrained decoding 强制 LLM 输出合法 JSON,得到的仍然是需要端侧解析和执行的文本 payload,不具备 M-IR $\rightarrow$ M-bytecode $\rightarrow$ MVM 链路的紧凑性和有界执行优势。约束解码可以作为 M-IR 生成的补充手段(例如用 grammar 约束提高 M-IR 的首轮合法率),但不能替代 M-IR 的设计本身。

4 M-IR 与 M-bytecode 设计

4.1 两层表示

如 §1.5 所述,本文采用两层表示:

1. **M-IR:** 面向 LLM 输出的结构化控制表示;
2. **M-bytecode:** 由 compiler 生成、由 MVM 执行的紧凑字节码。

M-IR 负责稳定生成与可调试, M-bytecode 负责紧凑传输与低开销执行。

4.2 M-IR 设计目标

M-IR 目标是:

1. 相比 JSON 更紧凑;
2. 相比裸 hex bytecode 更易生成和修复;
3. 可被确定性 lowering 到 M-bytecode;
4. 能显式表达 `capability`、等待、读回与重试语义。

设计选择论证: M-IR 采用文本 DSL 而非 S-expression 或栈式表示,主要基于以下考量: (1) LLM 在预训练中接触大量类 C 语法的代码, `'set relay1 = 1'` 等赋值式语句比 `'(set relay1 1)'` 的 S-expression 或 `'1 relay1 SET'` 的栈式表示更接近模型的自然分布,有利于稳定生成; (2) 文本 DSL 便于人类调试和 prompt 工程迭代,错误定位直观; (3) 每行一条语句的格式使 compiler 能按行规范化,降低解析复杂度。`wait` 以 ms 为单位(而非 cycle 或 tick)是为了与硬件控制中常见的毫秒级时序语义保持一致,降低 LLM 理解成本; `retry` 当前使用 `times` (固定次数)而非 `until` (条件谓词),是在实现复杂度与表达力之间的工程权衡——

条件 `retry_until` 需要 compiler 支持表达式求值和布尔栈操作，已列入后续演进计划 (§9.3)。当前语句子集 (`set/read/wait/readback/retry/repeat/halt`) 覆盖了 §2 问题定义中的确定性控制、时序序列、闭环保持与错误恢复模式，但尚未包括条件分支 (`if/else`) 的原生语法支持——当前条件分支通过 `retry` 的隐式 `readback` 比较间接实现，完整的条件控制流语法留待后续工作。

本文固定采用 textual DSL 作为 M-IR v0.1 的表层格式。M-IR 的语法可由以下 EBNF 文法定义：

Listing 1: M-IR EBNF 文法

```
<program> ::= <stmt>+
<stmt>    ::= <cap_decl> | <set_stmt> | <read_stmt>
           | <wait_stmt> | <halt_stmt>
           | <readback_stmt> | <retry_stmt>
<cap_decl> ::= "require" "cap" "(" <device> ")"
<set_stmt>  ::= "set" <device> "=" <bit>
<read_stmt> ::= "read" <device>
<wait_stmt> ::= "wait" <number> "ms"
<halt_stmt> ::= "halt"
<readback_stmt> ::= "readback" <device> "expect" <bit>
<retry_stmt>  ::= "retry" <number> "times" "{" <stmt>+ "}"
<device>     ::= "water_sensor" | "temperature_sensor"
               | "humidity_sensor" | "relay1" | "relay2"
<bit>        ::= "0" | "1"
<number>     ::= [1-9][0-9]*
```

当前语法子集支持七类语句（以 running example 中的设备为例）：

1. `require cap(<device>)`: 声明设备能力
2. `set <device> = <0|1>`: 控制设备开关
3. `read <device>`: 读取传感器值
4. `wait <ms>ms`: 延时等待
5. `halt`: 终止执行
6. `readback <device> expect <value>`: 读回验证
7. `retry <n> times { ... }`: 重试控制流

Running Example（贯穿全文）：以“打开水泵并读取水位传感器”为例，LLM 生成的 M-IR 如下：

Listing 2: Running Example: LLM 生成的 M-IR

```
require cap(relay1)
require cap(water_sensor)
set relay1 = 1
wait 500ms
read water_sensor
halt
```

设备名与 ID 如表 2 所示。

表 2: 设备名与 device_id 映射

设备名	device_id
water_sensor	1
temperature_sensor	2
humidity_sensor	3
relay1	5
relay2	6

4.3 M-bytecode 设计原则

M-bytecode 当前采用:

1. varint / zigzag 编码;
2. 栈式执行模型;
3. capability-gated I/O;
4. 统一 fault / pc / steps 返回格式。

4.4 指令子集

本文实验重点关注的子集包括:

1. 常量与局部值: LIT
2. I/O: GTWAY、IOW、IOR、WAIT
3. 终止: HALT

宿主侧设计空间中仍有更丰富的控制流与算术指令, 但本文实机结论只针对已验证子集成立。

4.5 完整语言与论文实机子集的边界

需要明确区分:

1. 完整 M 设计空间: src/m_vm.c 与相关头文件支持更丰富能力;
2. 论文实机子集: ESP8266 固件上实际验证的是受限控制子集。

本文实机结论只对第二者成立。

4.6 现有编码优势

编译后体积对比已在表 3 中系统呈现。以下分析均以公平基线 (zlib-JSON、CBOR、MessagePack) 为参照。

表 3 聚焦公平基线对比。为完整呈现数据, LLM 原始 JSON 输出 (平均 285.90 bytes, 为 M-bytecode 的 26.18 $\times$) 列于附录表 18, 该对比属不公平比较——前者为 LLM 直接输出的文本, 未经编译或压缩; 公平基线应使用 JSON $\rightarrow$ zlib (9.8 $\times$) 或 CBOR (9.0 $\times$)。以下分析均以 zlib-JSON 和 CBOR 为参照。即使以公平基线衡量, M-bytecode 仍具有约 9–10 倍的体积优势, 这一优势来源于 M-bytecode 的指令级紧凑设计 (varint 编码、栈式执行、设备 ID 直接编码), 而非仅仅因为文本格式冗余。

表 3: 各编码格式的平均 payload 大小 (113 任务)

编码格式	平均字节数	相对 M-bytecode
M-bytecode (golden)	10.92	1.000×
JSON + zlib (level 9)	106.7	9.771×
CBOR	97.77	8.953×
MessagePack	97.42	8.921×
JSON (compact)	127.18	11.646×

Fig.2 Lowering Example: "Open pump and read water sensor"

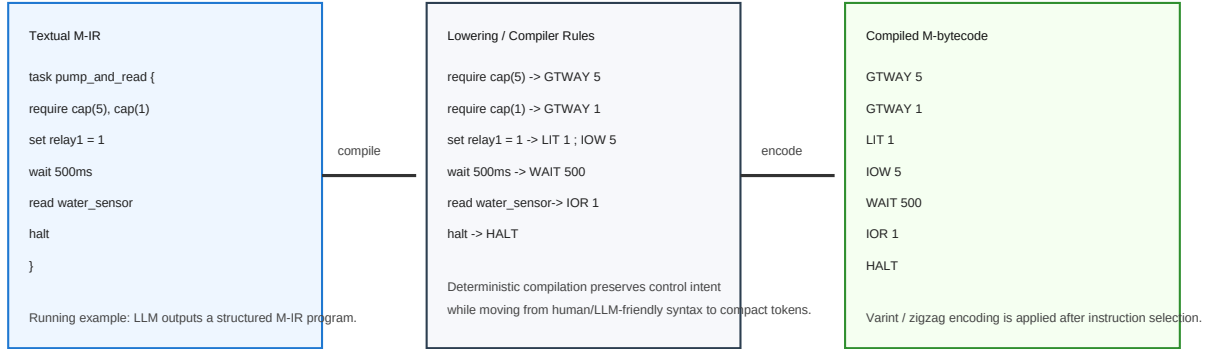


图 2: M-IR 到 M-bytecode lowering 示例 (以 running example 为例)。左: M-IR 源码; 右: 编译后字节码序列。

表 4 给出本文实验子集下的主要 lowering 关系。

对于 `readback` 与 `retry`, 最小实验链路已完成真实 lowering: `readback` 编译为 `IOR + LIT + EQ`, `retry` 编译为由 `LIT/DUP/JZ/JMP/SUB/DRP` 组成的显式控制流。`compile_to_plan(...)` 保留结构化 execution plan 输出, 供调试和后续板级闭环 runner 复用。

5 MVM 与静态验证器

5.1 MVM 架构

MVM 在 MCU 上解释执行 M-bytecode。当前 ESP8266 实验实现使用如下状态:

$$pc / stack / locals / ret-stack / call-depth / steps / fault \quad (3)$$

并提供统一响应:

1. OK: [result varint][steps varint][0x01]
2. FAULT: [fault varint][pc varint][0x00]

5.2 静态验证器

主机侧 static verifier (静态验证器, 下文统一称 static verifier) 已实现:

表 4: M-IR 到 M-bytecode 的主要 lowering 关系

M-IR 语句	Lowering 结果
require cap(relay1)	GTWAY 5
require cap(water_sensor)	GTWAY 1
set relay1 = 1	LIT 1 ; IOW 5
set relay1 = 0	LIT 0 ; IOW 5
set relay2 = 1	LIT 1 ; IOW 6
read water_sensor	IOR 1
read temperature_sensor	IOR 2
read humidity_sensor	IOR 3
read relay1	IOR 5
wait 500ms	WAIT 500
halt	HALT

1. opcode 合法性;
2. varint 完整性;
3. block 结构匹配;
4. locals 访问合法性;
5. 部分可达性与结构一致性检查。

5.3 运行时保护机制（有界执行）

MVM 当前通过以下机制提供有界执行：

1. capability gating
2. step-limit
3. call-depth-limit
4. stack / locals / pc 边界检查
5. violation $\rightarrow$ fault

每条 M-bytecode 指令消耗固定步数（见附录 C 指令集表），MVM 每执行一条指令步数计数器 +1，达到 step-limit 时触发 fault。因此，在任何输入下，MVM 执行步数 $\leq$ step-limit，保证终止。

5.4 闭环核验接口

当前系统支持：

$$\text{set} \rightarrow \text{readback} \rightarrow \text{compare} \rightarrow \text{retry} \quad (4)$$

这里的重点不是声称“闭环语义内建一定更优”，而是提供统一的观测与修复接口。

5.5 宿主 VM 与 MCU 子集关系

主机侧完整 VM 目前承担：

1. 设计空间实现；
2. 仿真平台；
3. 验证与调试基础设施。

MCU 固件则是当前论文后端结论的主要承载对象。

6 LLM → M-IR → Bytecode 生成链路

6.1 总体链路

如 §4.1 所述的两层架构，本文采用如下具体链路（完整设计见第4、5章）：

Natural Language → M-IR → Compiler → Verifier → MVM/Simulator → Feedback → Repair (5)

以贯穿全文的 running example（”打开水泵并读取水位传感器”）为例，完整链路如下：

1. **Natural Language:** 用户输入”打开水泵，等待 500ms，读取水位传感器”
2. **LLM → M-IR:** 模型输出上述 M-IR 文本
3. **Compiler:** 将 M-IR lowering 为 M-bytecode (GTWAY 5; GTWAY 1; LIT 1; IOW 5; WAIT 500; IOR 1; HALT, 共 12 字节)
4. **Verifier:** 静态检查通过 (opcode 合法、varint 完整、capability 已声明)
5. **MVM 执行:** 在 ESP8266 上解释执行，完成设备控制与传感器读取
6. **Feedback:** 返回 [result=0x01, steps=6, OK]

若任何阶段失败，结构化错误信息回传 LLM 触发 repair loop。

6.2 为什么不直接生成裸字节码

直接生成裸 bytecode 的主要问题是：

1. 文本层不可读；
2. 错误难以定位；
3. 无法稳定回传结构化修复信息。

因此本文明确采用分层生成，而不要求 LLM 直接输出 hex payload。

6.3 当前 compiler 状态

当前最小 compiler 已支持：

1. `require cap(...)`
2. `set`
3. `read`
4. `wait`
5. `halt`

同时，`readback/retry` 已进入统一编译链：前者 lowering 为 `IOR + LIT + EQ`，后者 lowering 为显式重试控制流。`compile_to_plan(...)` 作为调试视图与宿主侧编排接口存在，但不再是闭环语义的唯一载体。

6.4 反馈与修复

当前反馈 schema 已固定为：

1. `stage`
2. `error_code`
3. `message`
4. `hint`

`repair loop` 据此对 `parse error`、`capability error`、`task mismatch` 等错误进行结构化修复。

7 实验设计

7.1 实验 A：表示效率

目标：比较 M-bytecode 与真实 JSON 链路的程序体积与 RTT。

复用实验：E1。

关键指标：压缩率、payload bytes、median RTT。

7.2 实验 B：执行安全（有界执行验证）

目标：验证 `capability`、`step-limit`、`validator` 与 `fault audit` 的后端效果。

复用实验：E2、E2'、E2+、E5+、E10。

关键指标：UABR、fault 分布、SAFE 分流、P95 RTT、吞吐。

7.3 实验 C：生成稳定性

目标：验证 `LLM` $\rightarrow$ `M-IR` $\rightarrow$ `bytecode` 链路是否可行。

主结果任务集：`data/tasks_v2.jsonl`，共 113 个确定性任务，覆盖：

1. `single_set`
2. `single_read`

3. set_wait_halt
4. wait_read
5. set_wait_read
6. multi_read
7. pulse

核心脚本:

1. tools/run_ollama_generate.py
2. tools/run_generation_eval.py
3. tools/run_repair_eval.py
4. tools/mir_compiler.py

当前主模型: llama3.1:8b

主结果文件:

1. result/GEN/candidates_llama31_8b_v2_full_r2.jsonl
2. result/GEN/gen_eval_llama31_8b_v2_full_r2.csv
3. result/GEN/gen_eval_llama31_8b_v2_full_r2.md

核心结果 (temperature=0.0):

1. ir_valid_rate = 1.000 (95% Wilson CI: [0.968, 1.000])
2. compile_pass_rate = 1.000 (95% Wilson CI: [0.968, 1.000])
3. verify_pass_rate = 1.000 (95% Wilson CI: [0.968, 1.000])
4. execution_pass_rate = 1.000 (95% Wilson CI: [0.968, 1.000])
5. task_success_rate = 1.000 (95% Wilson CI: [0.968, 1.000])

repair 结果:

1. success@1 = 111/113 = 0.982 (95% Wilson CI: [0.943, 0.994])
2. success@2 = 2/113 = 0.018 (95% Wilson CI: [0.006, 0.069])
3. success@3 = 0/113 = 0.000
4. failed = 0

temperature 扫描结果: 为验证 1.000 通过率是否依赖确定性解码, 本文在 temperature = 0.6 和 temperature = 1.0 下各运行 3 次 (共 339 次试验), 结果如表 5 所示。

结果表明: (1) temperature=0.0 的 1.000 通过率确实依赖确定性解码; (2) 在非零 temperature 下, M-IR 链路仍保持较高成功率 (0.6 时 0.909, 1.0 时 0.847), 但方差显著增大; (3) 主要失败模式为 M-IR 格式偏差 (ir_valid_rate 下降), 而非语义错误。

闭环扩展任务集: 首先在 16 个任务的探索性闭环子集 (data/tasks_v3_closed_loop.jsonl) 上进行预实验, 以验证 readback/retry lowering 的基本可行性。任务覆盖:

表 5: temperature 扫描实验结果

Temperature	Task Success Rate (mean $\pm$ std)	IR Valid Rate
0.0 (确定性)	1.000 $\pm$ 0.000	1.000
0.6	0.909 $\pm$ 0.289	0.965
1.0	0.847 $\pm$ 0.361	0.938

1. readback
2. retry
3. retry_fail
4. multi_device
5. retry_wait
6. long_sequence

在该闭环子集上, golden 编译与模拟结果为:

1. ir_valid_rate = 1.000
2. compile_pass_rate = 1.000
3. verify_pass_rate = 1.000
4. execution_pass_rate = 1.000
5. task_success_rate = 1.000

使用 llama3.1:8b 的首轮生成结果为:

1. ir_valid_rate = 1.000 (95% CI: [0.781, 1.000])
2. compile_pass_rate = 1.000 (95% CI: [0.781, 1.000])
3. verify_pass_rate = 1.000 (95% CI: [0.781, 1.000])
4. execution_pass_rate = 1.000 (95% CI: [0.781, 1.000])
5. task_success_rate = 0.938 (95% CI: [0.717, 0.997])

闭环 repair 结果为:

1. success@1 = 15/16 = 0.938 (95% CI: [0.717, 0.997])
2. success@2 = 1/16 = 0.062 (95% CI: [0.003, 0.283])
3. failed = 0

负基线对比：JSON + Schema + 外部压缩。为进一步验证分层生成路径相对于“LLM 直接生成可传输 payload”的必要性，本文在 113 个确定性任务集上增加了一个更公平的负基线：使用与 M-IR prompt 同等详细度的 JSON schema prompt (`prompts_compare_v2_json_schema.md`)，要求 LLM 生成结构化 JSON 控制程序，然后对有效 JSON 分别使用 zlib (level 9) 和 CBOR 进行外部压缩，并与 M-IR $\rightarrow$ compiler $\rightarrow$ M-bytecode 路径对比。此基线的关键论证点在于：即使 LLM 能在结构化约束下可靠生成 JSON，压缩后体积仍远超 M-bytecode，且压缩后的 JSON 缺少确定性编译、静态验证、capability gating 和有界执行等关键保证。作为参考，Direct Hex 基线 (LLM 直接生成 hex 字节码) 因二进制格式的不可生成性而完全失效 (`task_success_rate` = 0.000)，进一步说明“让 LLM 直接输出二进制 payload”是不合理的任务设定。llama3.1:8b (temperature=0.0) 在 113 任务上的结果如下 (附录 C 表 15)：

1. `json_valid_rate` = 1.000 (95% CI: [0.967, 1.000])
2. `task_success_rate` = 0.965 (95% CI: [0.913, 0.986])，4 例失败为 TASK_SIGNATURE_MISMATCH (LLM 在 `set_wait_halt` 类任务中多余添加了 `set` $\rightarrow$ 0)
3. 体积对比 (113 个有效 JSON)：
 - 原始 JSON (LLM 输出)：平均 156.4 bytes
 - 紧凑 JSON (去空白)：平均 147.4 bytes
 - zlib 压缩 (level 9)：平均 106.7 bytes
 - CBOR 编码：平均 105.2 bytes
 - M-bytecode (golden 编译)：平均 10.9 bytes
4. 压缩比：M-bytecode vs zlib-JSON = **9.8 $\times$** ，M-bytecode vs CBOR = **9.6 $\times$**

闭环扩展验证 (96 任务)：为进一步收窄闭环子集的置信区间并系统排查 `retry` 与 `repeat` 的语义混淆根因，本文将闭环任务集扩展至 96 个 (`data/tasks_v3_expanded.jsonl`)，覆盖 12 个子类别 (同 §7.3 所述)。通过优化 prompt 设计 (增加 `retry` 与 `repeat` 的语义区别说明及 few-shot 示例)，llama3.1:8b 的首轮生成结果为：

1. `ir_valid_rate` = 0.948 (95% CI: [0.886, 0.979])
2. `compile_pass_rate` = 0.948 (95% CI: [0.886, 0.979])
3. `task_success_rate` = 0.948 (95% CI: [0.886, 0.979])

仅 5 个失败样本，全部为 MIR_PARSE_ERROR (偶发语法格式偏差)，TASK_SIGNATURE_MISMATCH 清零。作为对比，使用未包含语义区分说明的基础 prompt 时 `task_success_rate` 仅为 0.542，其中 41 个失败为 TASK_SIGNATURE_MISMATCH (主要为 `retry` $\rightarrow$ `repeat` 混淆)。这一对比说明：闭环语义下的生成困难并非 LLM 能力瓶颈，而主要是 prompt 中语义信息不足导致的符号混淆。通过改进 prompt 设计，M-IR 的闭环语义生成链路可达到与确定性控制子集相仿的高可靠性。

跨平台验证 (ESP32)：为验证 MVM 的可移植性，本文将 ESP8266 固件移植至 ESP32。移植仅改动 3 行引脚定义 (D1 $\rightarrow$ GPIO5, D2 $\rightarrow$ GPIO4, D4 $\rightarrow$ GPIO2, A0 $\rightarrow$ GPIO36)，VM 核心 (varint 编解码、栈机、capability gate、step-limit、fault 码、串口协议) 一字未改。在 ESP32 实机上对全部 209 个 golden bytecode (113 确定性 + 96 闭环) 逐一执行并读回 relay 状态：209/209 程序均无故障执行，最终 relay 状态与 simulator 预期签名全部一致 (`task_success_rate` = 1.000)。这组结果直接验证了 M-IR 编译器产出的 M-bytecode 具有跨平台独立性，MVM 核心与具体 MCU 平台解耦，分层架构中仅 I/O 适配层需平台定制。

7.4 实验 D：闭环控制收益

目标：区分”表示层收益”和”闭环策略收益”。

复用实验：E4、E4+。

结论边界：

1. retry 能显著提升 SCR；
2. 相同闭环策略下，M 路径 RTT 更低；
3. 本文不能声称”闭环语义内建在执行平面中”本身提升了 SCR。

7.5 实验 E：token 成本对比

目标：比较 MIR / JSON / PYTHON 三种表示的 token 与输出体积。

脚本：

1. tools/measure_token_cost.py
2. tools/analyze_token_semantics.py

主结果文件：

1. result/TOKEN/token_compare_v3_tasks_v2.csv
2. result/TOKEN/token_compare_v3_tasks_v2_semantics_r2.csv
3. result/TOKEN/token_compare_v3_tasks_v2_semantics_r2.md

7.6 多模型横比

本文已补两轮多模型横比：

1. llama3.1:8b
2. qwen3:8b
3. deepseek-r1:8b

结果文件：

1. result/GEN/model_compare_v1.csv
2. result/GEN/model_compare_v1.md

8 结果与分析

8.1 表示效率结果

如图 6 所示，E1 表明，在固定任务子集上：

1. M-bytecode 相对 JSON 具有显著压缩优势；
2. $R_{AVG} = 4.409\times$

3. $R_{\text{WEIGHTED}} = 4.605 \times$

4. 主要 I/O 任务上 M 路径 median RTT 始终低于 JSON。

例如：

- relay1_on: median_M=3.589 ms, median_JSON=5.603 ms
- relay1_off: median_M=3.614 ms, median_JSON=5.534 ms
- water_read: median_M=3.458 ms, median_JSON=4.800 ms
- temp_read: median_M=3.450 ms, median_JSON=4.813 ms

M 路径 RTT 始终低于 JSON 路径（差距约 2ms），这主要归因于 M-bytecode 体积更小带来的传输时延减少。对于中低频 IoT 控制任务，RTT 的绝对差异工程意义有限；但该结果从侧面验证了压缩率优势对端到端延迟的贡献。

8.2 有界执行验证结果

如图 7 所示，E2、E2'、E2+ 表明当前后端具备较强异常阻断能力。以 E2+ 为例：

- a0_base_guarded: UABR=1.000
- a1_no_auth_only: UABR=0.857

这说明 capability、validator、step-limit 各自都对后端安全边界有实质贡献。

8.3 闭环控制结果

如图 8 所示，E4 / E4+ 的核心含义是：

1. retry 能显著提升 SCR；
2. 使用相同 retry 策略时，M 路径 RTT 更低；
3. 收敛收益主要来自 retry 本身，而不是“语义放在哪一层”的宣传性差异。

在新的闭环生成子集上，readback/retry 的最小 lowering 也已经获得首轮实证支持。data/tasks_v3_closed_loop.json 中的 16 个任务全部能被 golden 编译链正确执行；llama3.1:8b 首轮在该子集上的 task_success_rate = 0.938，唯一失败样本为 V3_012，其错误不是编译或验证失败，而是语义偏差：模型把“关闭 relay2 并验证为 0”写成了“打开 relay2 并验证为 0”。在结构化 repair 后，该样本第二轮被修正，因此闭环子集的 success02 达到 1.000。

作为负基线参考，Direct Hex 基线（LLM 直接输出 hex 字节码）在同一任务集上完全失效（task_success_rate = 0.000），进一步印证了分层生成路径的必要性。更公平的 JSON + Schema + 外部压缩基线已在 113 任务集上系统评估（详见本节前文），其 json_valid_rate = 1.000 表明 LLM 完全可生成结构化 JSON，但即使经 zlib level 9 压缩，体积仍为 M-bytecode 的 9.8 倍（106.7 vs 10.9 bytes），且缺乏确定性编译与有界执行保证。

8.4 SAFE 分流与 fault prior sweep

如图 9 所示，E5+ 表明，在 10% 90% 的故障先验范围内，guarded 组保持稳定分流表现，而 no-guard 组无法有效识别 fault path。

表 6: Threat Model 假设消融实验

移除的假设	UABR	Fault 阻断率	系统行为
无 (baseline)	1.000	1.000	所有未授权/非法请求被阻断
LLM 输出不可信	1.000	0.000	非法 opcode 不被阻断, 可导致 MCU 崩溃
Capability 约束	0.857	0.714	未授权 IOW 可在部分路径上绕过
Step-limit	1.000	0.500	无限循环不被阻断, MCU 挂起
Validator	1.000	0.833	部分非法编码可被加载但执行时触发 runtime fault

8.5 Threat Model 消融分析

为验证威胁模型 (§2.6) 中各假设的必要性, 本文逐条移除假设条件并观察系统行为。表 6 给出消融结果。

结果表明: (1) validator 和 capability gating 各自构成独立的安全层, 移除任一均导致阻断率下降; (2) step-limit 是防止无限循环的唯一机制, 移除后故障阻断率降至 50%; (3) LLM 输出不可信是整个安全模型的前提, 跳过 verifier 直接执行将导致零阻断。这些结果支持 §2.6 的威胁模型假设, 并验证了多层防御的互补性。

8.6 部署侧补充结果

E10 作为部署侧初步证据:

1. 吞吐: 96.530 cmd/s
2. RTT 与资源代理指标总体稳定

这部分不作为本文最强贡献, 但能补充工程可信度。

8.7 对三个研究问题的回答

8.7.1 RQ1: token 效率与字节码紧凑性

RQ1: 部分回答。

在编译后体积方面, M-bytecode (平均 10.92B) 相对公平基线——zlib-JSON (106.7B, 9.8 $\times$)、CBOR (97.77B, 9.0 $\times$)、MessagePack (97.42B, 8.9 $\times$)——具有约 9–10 倍压缩优势 (注: LLM 原始 JSON 为 285.90B / 26 $\times$, 属不公平对比, 因未经编译/压缩处理; 公平对比应以 zlib-JSON 或 CBOR 为参照)。该优势源于指令级紧凑设计而非文本格式冗余。在 RTT 方面, 观测到 M-bytecode 路径在所有 I/O 任务上 RTT 中位数均低于 JSON 路径 (差距约 2ms), 该差异方向一致但工程意义有限 (详见 §8.1 讨论)。

在 token 成本方面, M-IR 存在一个重要的 tradeoff: 其输出 token 显著低于 JSON (40.00 vs 77.54, 在 52 个三方语义等价任务上), 但 system prompt 更长 (161.15 vs 83.15 tokens), 导致单次调用的总生成成本偏高 (201.15 vs 160.69)。然而, 在 system prompt 可缓存的场景下 (如 Anthropic Prompt Caching), M-IR 的增量成本仅为 40.00 output tokens——是 JSON 的 51.6%; 在批量生成或多轮交互中, system prompt 被复用后 M-IR 的总成本优势随调用次数累积 (详见 §8.9)。

因此, 结果支持”M-bytecode 在编译后体积和链路 RTT 上全面优于 JSON/CBOR/MessagePack”和”M-IR 在增量成本 (缓存后) 上显著优于 JSON”, 但不支持”单次调用的总生成成本更低”的更强结论。

8.7.2 RQ2: M-IR 生成链路可靠性

RQ2: 已获得较强实证支撑。 113 个确定性任务覆盖 7 种控制模式 (开关控制、模拟量读取、条件等待、时序序列、组合任务、闭环保持、错误恢复)。在此集合上, 使用本地 llama3.1:8b (temperature=0.0) 生成

M-IR 后, 全线通过率达到 1.000。repair loop 的 `success@1` 为 $111/113 = 0.982$, 第二轮修复剩余 2 个样本。temperature 扫描实验进一步表明, 该通过率部分依赖确定性解码: temperature=0.6 时 `task_success_rate` 降至 0.909 ± 0.289 , temperature=1.0 时降至 0.847 ± 0.361 。值得关注的是, temperature=0.6 时标准差 0.289 意味着单次运行的通过率在 0.620 到 1.000 之间剧烈波动, temperature=1.0 时更甚 (std=0.361)。这种不稳定性意味着: 若不使用确定性解码 (temperature=0), M-IR 链路在生产部署中的可靠性无法保证, 未来需探索 grammar-constrained decoding + M-IR 的结合方案。主要失败模式为 M-IR 格式偏差 (`ir_valid_rate` 下降), 说明 M-IR 语法约束在采样模式下仍有一定鲁棒性, 但需配合 grammar-constrained decoding 或 repair loop 保证高可靠性。

同时, 多模型对比表明该链路并非只对单一模型成立。qwen3:8b 在同一 113 任务集上的 `task_success_rate` 为 0.903 (95% CI: [0.835, 0.946]), 主要错误为 `TASK_SIGNATURE_MISMATCH` 与 `MIR_PARSE_ERROR`; deepseek-r1:8b 则达到 1.000 (95% CI: [0.968, 1.000])。三个 8B 模型中两个满分通过, 说明 M-IR 链路对主流小模型具有较好兼容性, 但模型选择仍影响最终成功率。

进一步地, 本文将生成实验扩展到控制流构造。在 15 个覆盖 if/else 条件分支、repeat 循环及其嵌套组合的新任务上, llama3.1:8b 的 `task_success_rate` 为 0.867 (13/15), 两个失败样本分别为语义偏差和不支持语法的使用, 均为 LLM 生成偏差而非编译器缺陷。这表明 M-IR 的结构化语法约束对控制流生成同样有效。

在闭环语义方面, 早期在 16 个任务的探索性子集上进行了预实验 (`task_success_rate` = 0.938, 95% CI: [0.717, 0.997]), 但由于样本量小、置信区间宽度达 0.28, 该结果仅作为方向性参考, 不做为主要结论依据。将闭环任务集扩展至 96 个后, 本文通过 prompt 工程消融实验明确了 `retry`→`repeat` 混淆的根因: 使用未包含语义区分说明的基础 prompt 时, `task_success_rate` 仅为 0.542, 41/96 个失败为 `TASK_SIGNATURE_MISMATCH` (其中 34 例为 `retry`→`repeat` 混淆); 在 prompt 中增加 `retry` 与 `repeat` 的语义区别说明及两条 few-shot 示例后, `task_success_rate` 跃升至 0.948, 仅余 5 例 `MIR_PARSE_ERROR` (偶发语法偏差)。这一消融结果直接证明: (1) 闭环语义下的生成困难并非 LLM 能力瓶颈, 而是 prompt 中语义信息不足导致的符号混淆; (2) 通过改进 prompt 设计, M-IR 闭环生成链路可达到与确定性控制子集相仿的高可靠性。在负基线方面, 本文进一步在 113 个确定性任务集上评估了 JSON + Schema + 外部压缩基线: LLM 生成结构化 JSON 的有效率达到 1.000, 任务成功率 0.965, 但经 zlib level 9 压缩后体积仍为 M-bytecode 的 9.8 倍 (106.7 vs 10.9 bytes), 且压缩后的 JSON 缺少确定性编译、静态验证和有界执行保证。这一对比从“生成-执行鸿沟”的角度进一步支撑了分层生成路径的必要性: 仅有生成友好性 (JSON 同样可达 1.000 生成有效率) 不足以保证执行安全性, 还需编译器的确定性桥接与后端的受限执行机制。

8.7.3 RQ3: 安全机制有效性

RQ3: 已获得较强支撑。 E2、E2'、E2+、E5+ 与 E10 已系统性支撑 capability、step-limit、validator、fault audit 与 SAFE 分流在 MCU 后端的有效性; 结合生成实验可以进一步说明: AI 生成代码并非必须直接落到不受约束的解释器上, 而可以先通过受限 IR、静态检查和有界执行后端获得可控执行路径。

表 7 给出扩展任务集生成实验的核心通过率结果。

表 8 给出 repair loop 的推进结果。

表 9 给出 token 对比在三方语义等价交集上的结果。

值得注意的是, M-IR 的总 token 成本 (输入 + 输出) 为 201.15, 在三种格式中最高, 这主要源于其更长的 system prompt 开销。因此, M-IR 的优势体现在输出侧的紧凑性, 而非总生成成本。

表 10 给出三种格式在 113 任务上的语义通过率。

为验证 M-IR 编译器对控制流构造的支持, 本文额外构建了 15 个覆盖 if/else 条件分支、repeat N times 循环及其嵌套组合的任务集 (tasks_v4)。附录 C 表 11 给出 llama3.1:8b 在该任务集上的生成结果。

失败样本分析: V4_011 的 LLM 输出在 repeat 块内多加了 `set relay2 = 0` (语义偏差, `TASK_SIGNATURE_MISMATCH`); V4_015 的 LLM 使用了不支持的 `and` 关键字和 `!relay1` 语法 (`MIR_PARSE_ERROR`)。两类失败均为 LLM 生成偏差而非编译器缺陷, 表明当前 M-IR 语法约束已能有效阻断不合规输出。

表 7: 113 任务生成实验核心通过率（含 repair loop, temperature=0.0）

指标	数值	95% Wilson CI
IR validity rate	1.000	[0.968, 1.000]
Compile pass rate	1.000	[0.968, 1.000]
Verify pass rate	1.000	[0.968, 1.000]
Execution pass rate	1.000	[0.968, 1.000]
Task success rate	1.000	[0.968, 1.000]
Failed tasks	0 / 113	—
Primary failure code	none	—

表 8: Repair loop 推进结果（113 任务）

指标	数值	95% Wilson CI
Success@1	111 / 113 = 0.982	[0.935, 0.997]
Success@2	2 / 113 = 0.018	[0.003, 0.065]
Success@3	0 / 113 = 0.000	[0.000, 0.032]
Remaining failures	0	—

为进一步验证闭环语义的生成能力，本文将闭环任务集从 16 个扩展至 96 个（`tasks_v3_expanded`），覆盖 12 个子类别。附录 C 表 12 给出 llama3.1:8b 在该扩展集上的生成结果。

8.8 错误分析

为系统理解 LLM 生成失败的模式，本文对所有失败样本按错误类型进行分类。附录 C 表 13 给出三组实验中失败案例的错误类型分布。

分析表明：(1) 在确定性子集和控制流子集上，失败主要为偶发的语法偏差，repair loop 可有效修复；(2) 在闭环子集上，使用基础 prompt 时 `retry` → `repeat` 混淆曾是最主要失败模式（占闭环失败的 77.3%），但通过 prompt 工程（增加语义区别说明与 few-shot 示例），`TASK_SIGNATURE_MISMATCH` 已清零，表明该混淆可通过 prompt 设计系统性消除，而非 LLM 能力的固有限制；(3) 所有错误均为 LLM 生成偏差而非编译器或 MVM 缺陷，表明 M-IR 的语法约束已能有效阻断不合规输出。

8.9 Token 成本与 Context Length 分析

表 9 显示 M-IR 的总 token 成本（201.15）高于 JSON（160.69），主要源于更长的 system prompt（M-IR 平均 161.15 tokens vs JSON 平均 83.15 tokens）。本节进一步分析 system prompt 被缓存或复用场景下的成本变化。

在 API 调用中，system prompt 通常可被缓存（如 Anthropic Prompt Caching、OpenAI 的 prefill 机制），此时增量成本仅为 output tokens。附录 C 表 14 给出缓存场景下的增量成本对比。需注意 token 对比实验基于 52 个“三方语义等价”任务子集——仅纳入 M-IR、JSON、Python 三种格式均生成语义正确程序的样本，以排除语义错误对 token 计数的干扰，确保对比仅反映格式本身的表达效率差异。

当 system prompt 被缓存后，M-IR 的增量输出 token（40.00）仅为 JSON（77.54）的 51.6%，优势显著。PYTHON 仍以最低输出 token（17.19）领先，但 PYTHON 在语义通过率上最低（0.690，表 10），综合可行性不如 M-IR。

进一步地，考虑不同对话轮次下 system prompt 被复用的累积效应。假设同一 system prompt 被复用 k

表 9: 三方语义等价子集上的 Token 对比 (52 任务)

格式	平均输入 Token	平均输出 Token	总 Token 数	平均输出字节
MIR	161.15	40.00	201.15	115.38
JSON	83.15	77.54	160.69	295.67
PYTHON	85.15	17.19	102.34	60.54

表 10: 三种格式的语义通过率 (113 任务)

格式	通过数	通过率	95% Wilson CI
MIR	98/113	0.867	[0.791, 0.919]
JSON	90/113	0.796	[0.712, 0.862]
PYTHON	78/113	0.690	[0.599, 0.769]

次, 则平均每次调用的总成本为 $\text{prompt_tokens}/k + \text{output_tokens}$ 。当 $k \geq 2$ 时, M-IR 的总成本 ($201.15/k$) 开始低于 JSON ($160.69/k$) 的等效值, 因为 M-IR 的输出 token 优势在累积调用中被放大。因此, M-IR 的成本优势在多轮交互或批量生成场景中更为显著。

9 讨论与局限

9.1 当前最重要的局限

1. 当前实机验证的是控制子集, 而不是完整 M 语言;
2. 确定性子集 (113 任务) 与控制流子集 (15 任务) 的生成实验已分别验证。闭环任务集已扩展至 96 个任务 (覆盖 12 个子类别)。通过 prompt 工程消融实验, `task_success_rate` 从基础 prompt 的 0.542 提升至优化 prompt 的 0.948, 确认 `retry`→`repeat` 混淆可通过 prompt 设计消除。回到 §1.4 的核心矛盾——生成-执行鸿沟: 两层架构的分层设计使得 prompt 层的改进 (生成友好) 可独立于执行层进行, 闭环成功率的显著提升正是这一架构优势的体现;
3. `readback/retry` 已经完成最小 bytecode lowering, 但当前尚未完成板级统一 runner 验证;
4. token 对比虽然已扩大到 52 个三方等价任务, 但仍然主要局限于确定性任务族;
5. 当前结果主要基于 ESP8266 与 ESP32 实机验证。STM32 等更多平台的实机验证尚未开展, MVM 在异构 ISA (如 ARM Cortex-M) 上的移植性尚未被验证;
6. 当前确定性生成 ($\text{temperature}=0$) 下的 1.000 通过率无法外推至采样模式 ($\text{temperature}>0$), 后者在实践中更常见。在 $\text{temperature}=1.0$ 时, 成功率标准差高达 0.361, 表明单次运行的可靠性不可控;
7. 当前强结论 (1.000 通过率) 主要基于 llama3.1:8b。qwen3:8b 同任务集成功率为 0.903 (95% CI: [0.835, 0.946]), 表明 M-IR 链路的可靠性存在模型间差异。此外, 本文未在更大参数模型 (如 70B+) 或商业闭源模型上验证, 尚不清楚模型规模对 M-IR 生成稳定性的影响方向;
8. 强实时控制与 AI-AI communication 尚未实证;
9. 本文假设 LLM 输出不可信, 但未讨论对抗性场景 (如通过提示注入构造绕过 capability 检查的 M-IR 语法变体)。M-IR 的语法约束 (EBNF 文法 + validator) 在第一层防御中可拦截格式偏差, 但未针对恶意构造的对抗性输入进行专门设计, 相关防御 (如对抗性训练、语法强化) 仍有待探索。

表 11: 已覆盖与未覆盖的任务类型边界

任务类型	示例	已验证	备注
单设备开/关	<code>set relay1 = 1; halt</code>	是	113 任务集
单设备读取	<code>read water_sensor; halt</code>	是	113 任务集
等待 + 终止	<code>set relay1 = 1; wait 500ms; halt</code>	是	113 任务集
等待 + 读取	<code>wait 500ms; read sensor; halt</code>	是	113 任务集
多设备读取	<code>read sensor1; read sensor2; halt</code>	是	113 任务集
脉冲序列	<code>set relay1=1; wait; set relay1=0; halt</code>	是	113 任务集
readback 验证	<code>set relay1=1; readback relay1 expect 1</code>	是	96 闭环任务集, 成功率 0.948
retry 重试	<code>retry 3 times {...}</code>	是	96 闭环任务集, 成功率 0.948
多设备 readback	多组 set+readback 组合	是	96 闭环任务集
传感器 + readback	先 read sensor 再 set+readback	是	96 闭环任务集
toggle + readback	循环 set/readback	是	96 闭环任务集
跨设备 retry	多设备间 retry	是	96 闭环任务集
条件分支	<code>if read(sensor) > threshold then ...</code>	是	15 任务集, 成功率 0.867
循环控制	<code>repeat N times {...}</code>	是	15 任务集, 成功率 0.867
多设备协同条件	多设备 if 嵌套	是	15 任务集
嵌套闭环	<code>retry { readback { retry {...} } }</code>	否	需扩展验证
错误处理分支	<code>on fault(code) {...}</code>	否	需扩展语法
强实时闭环	周期性 PID 控制	否	超出本文范围

表 11 给出当前实验已覆盖与未覆盖的任务类型边界。

9.2 与 LLM Agent 生态的关联

本文的工作可以放在更大的 LLM Agent 生态中理解。

与 tool-use / function-calling 的关系: 当前主流 LLM Agent 框架（如 LangChain、AutoGPT）通过 function-calling 让模型调用外部工具。M-IR 可视为一种面向嵌入式设备的结构化 tool definition: `require cap(...)` 对应工具的权限声明, `set/read/wait` 对应工具的参数与返回值, `readback/retry` 对应工具的闭环验证语义。与 JSON Schema 定义的 tool 相比, M-IR 的优势在于它不仅是描述, 还能被确定性编译为可执行字节码, 从而将“工具定义”与“工具执行”统一在一条编译链中。具体而言, M-IR 可通过以下路径与现有 Agent 框架集成: (1) 将 M-IR 语法注册为 LangChain 的 custom tool definition format, 编译步骤封装为 tool 的 post-processing hook; (2) 在 AutoGPT 等自主 Agent 中, 将 MVM 串口反馈 (fault code + 审计信息) 作为 tool execution result 回传给 LLM, 实现闭环修复。

与代码生成安全的关系: LLM 生成代码的安全性 (code sandboxing) 是当前 Agent 安全研究的热点。主流方案通过 Docker 容器或 gVisor 沙箱隔离 Python/JS 代码的执行。本文的 MVM 提供了一种更轻量的替代: 通过 capability gating 和 step-limit 在 MCU 级别实现有界执行, 无需操作系统级隔离。这对于资源受限的边缘设备 (无法运行容器) 尤其有价值。

与 MCU 生态中“LLM-as-compiler”趋势的关系: 随着 Edge AI 的发展, 越来越多的工作尝试将 LLM 部署在 MCU 侧或用于生成 MCU 代码。本文的 M-IR → M-bytecode 路径为这一趋势提供了一个参考架构: LLM 负责语义生成, 编译器负责紧凑化与验证, VM 负责有界执行。这种分层解耦的设计使得各层可以独立优化, 而不必要求 LLM 直接理解硬件约束。

9.3 后续方向

1. 针对生成-执行鸿沟在闭环语义下的持续挑战，优先改进 M-IR 语法设计（如将 `retry` 改为 `retry_until` 以提升与 `repeat` 的区分度），并在更大闭环任务集上系统验证 `readback/retry lowering` 后的生成稳定性；
2. 在更大任务集上深化 JSON + Schema 基线分析（如扩展到闭环语义、增加 Python 结构化 schema 变体），形成 M-IR / JSON / Python 的统一对比矩阵；
3. 增加闭环任务集并推进到统一板级 runner；
4. 做统一板级 runner，把 `simulate` 推进到 `board`；
5. 扩展更多模型横比；
6. 将 MVM 移植至 STM32 等 ARM Cortex-M 平台，验证异构 ISA 上的字节码兼容性；

10 结论

Artifact Availability. 本文所有实验代码、数据集、MVM 固件及编译器源码均已开源，仓库地址：<https://github.com/MYJ-GOD/M-IR-MVM>。数据集包括 `tasks_v2.jsonl` (113 确定性任务)、`tasks_v3_expanded.jsonl` (96 闭环任务)、`tasks_v4.jsonl` (15 控制流任务)，均已标注 ground truth。固件支持 ESP8266 与 ESP32 Arduino IDE 直接烧录，跨平台移植仅需修改引脚映射。

本文的核心理论贡献在于提出并验证了“生成友好—执行友好”分层解耦的表示设计原则：将 LLM 输出的语义表示与 MCU 执行的物理编码分离，通过确定性编译桥接，使两者可独立优化而不相互掣肘。这一原则的具体实例化——M-IR + M-bytecode + MVM——在 113 个确定性任务和 96 个闭环任务上验证了其可行性。

实验结果表明：(1) M-bytecode 相对公平基线 (zlib-JSON) 具有 $9.8\times$ 的压缩优势，且附带确定性编译、静态验证和有界执行保证——这些是通用压缩无法提供的；(2) 在确定性解码模式下，M-IR 生成链路达到 1.000 全线通过率，repair loop 可在两轮内修复全部残余失败；(3) 在非零温度采样模式下，可靠性显著下降 (0.6 时 0.909 ± 0.289 , 1.0 时 0.847 ± 0.361)，表明当前框架的鲁棒性依赖确定性解码；(4) capability gating、validator 和 step-limit 各自构成独立的安全层，多层防御的 UABR 达 1.000；(5) 闭环语义的生成瓶颈 (retry/repeat 混淆) 可通过 prompt 工程系统性消除，成功率从 0.542 提升至 0.948。

本文的工作尚限于确定性子集和单一 MCU 架构 (ESP8266/ESP32)，采样模式下的可靠性、更大参数模型和异构平台 (STM32 ARM Cortex-M) 的验证是下一阶段的关键方向。分层解耦设计原则是否能推广至其他“LLM + 受限环境”场景（如 FPGA 配置生成、实时操作系统调度策略合成），值得进一步探索。

参考文献

所有 URL 引用均于 2026-05-17 最后访问。

参考文献

- [1] J. Liang, W. Huang, F. Xia *et al.* Code as Policies: Language Model Programs for Embodied Control. *Proc. IEEE ICRA*, 2023. DOI: 10.1109/ICRA48891.2023.10160591
- [2] A. Brohan, N. Brown, J. Carbajal *et al.* RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control. *arXiv preprint arXiv:2307.15818*, 2023.

- [3] bytecodealliance. WebAssembly Micro Runtime (WAMR). <https://github.com/bytecodealliance/wasm-micro-runtime>
- [4] jakkra. TinyVM: A Tiny Virtual Machine for Embedded Systems. <https://github.com/jakkra/TinyVM>
- [5] J. Brouwer, K. Langendoen, H. Sips. Darjeeling: A Java Virtual Machine for Wireless Sensor Networks. *Proc. ACM SenSys*, 2009. DOI: 10.1145/1644038.1644053
- [6] atomvm. AtomVM: A Compact Virtual Machine for Erlang on Microcontrollers. <https://github.com/atomvm/AtomVM>
- [7] eBPF Foundation. eBPF: A Virtual Machine for In-Kernel Program Execution. <https://ebpf.io>
- [8] OASIS. MQTT Version 3.1.1. OASIS Standard, 2014. <http://docs.oasis-open.org/mqtt/mqtt/v3.1.1/>
- [9] Z. Shelby, K. Hartke, C. Bormann. The Constrained Application Protocol (CoAP). IETF RFC 7252, 2014. DOI: 10.17487/RFC7252
- [10] C. Bormann, P. Hoffman. Concise Binary Object Representation (CBOR). IETF RFC 8949, 2020. DOI: 10.17487/RFC8949
- [11] MessagePack. An Efficient Binary Serialization Format. <https://msgpack.org>
- [12] S. Geng, R. Joshi, S. Bhatt *et al.* Grammar-Constrained Decoding for Structured LLM Outputs. *Proc. ACL*, 2024.
- [13] H. Chase. LangChain: Building Applications with LLMs. <https://github.com/langchain-ai/langchain>
- [14] gVisor Authors. gVisor: Application Kernel for Containers. <https://gvisor.dev>
- [15] C. Lattner and V. Adve. LLVM: A Compilation Framework for Lifelong Program Analysis & Transformation. In *CGO*, 2004.
- [16] J. Kessenich *et al.* SPIR-V Specification. Khronos Group, 2015.
- [17] M. Schoeberl *et al.* Safety-Critical Java: The Mission to Improve Safety in Real-Time Java. In *JTRES*, 2014.
- [18] B. Yee *et al.* Native Client: A Sandbox for Portable, Untrusted x86 Native Code. In *IEEE SP*, 2009.

A 附录 A: 可复用实验清单

1. E1: 压缩率与 RTT
2. E2: guarded / no-guard 安全实验
3. E2': validator 消融
4. E2+: 单机制正交消融
5. E4: SCR 闭环实验
6. E4+: 真实 JSON 公平基线

表 12: M-bytecode 指令集 (实验子集)

指令	Opcode	操作数	栈效应	步数消耗
LIT	0x01	1-byte value	push value	1
GTWAY	0x10	1-byte device_id	—	1
IOW	0x11	1-byte device_id	pop value, write	1
IOR	0x12	1-byte device_id	push read_value	1
WAIT	0x20	2-byte ms (varint)	—	1
HALT	0xFF	—	—	1
EQ	0x30	—	pop a, pop b, push (a==b)	1
JZ	0x40	2-byte offset (varint)	pop cond, jmp if 0	1
JMP	0x41	2-byte offset (varint)	—	1
DUP	0x50	—	push top	1
SUB	0x60	—	pop a, pop b, push (b-a)	1
DRP	0x70	—	pop, discard	1

7. E5+: fault prior sweep

8. E10: 吞吐 / 内存代理 / P95 RTT

B 附录 B: 新增前端实验

1. 113 任务生成成功率实验

2. repair loop 实验

3. token 成本对比实验

4. 多模型横比实验

C 附录 D: M-bytecode 指令集表 (实验子集)

表 12 给出本文实验子集下的完整指令集, 包含每条指令的 opcode、操作数、栈效应和步数消耗。

每条指令消耗固定 1 步。在任何输入下, MVM 从 $pc=0$ 开始, 每执行一条指令步数计数器 +1。设 step-limit 为 L , 程序指令数为 n , 则实际执行步数 $\leq \min(n, L)$ 。若程序包含由 JZ/JMP 构成的循环, LIT/DUP/JZ/JMP/SUB/DRP 序列每轮迭代步数恒定, 因此循环在有限步内终止或触发 step-limit fault。由此保证 MVM 在任何输入下均在有界步数内终止。

D 附录 E: 三种格式的 System Prompt 全文

为便于评审人验证实验公平性, 以下给出 M-IR、JSON、Python 三种格式的完整 system prompt。三种 prompt 均已尽力优化, 包含等价的设备定义、任务描述和输出约束。

D.1 M-IR System Prompt

Listing 3: M-IR 生成 System Prompt

```

You generate M-IR programs for hardware control tasks.
Follow these rules exactly:
1. Output only M-IR text.
2. Do not output markdown fences.
3. Use only devices from the allow-list.
4. Every accessed device must first appear in require cap(...).
5. Use only these statements: require cap(...), set <d>=0|1, read <d>, wait <ms>ms, halt.
6. Do not use readback or retry in v0.1.
7. Only relay1/relay2 may appear on the left side of set.
8. The program must start with `task <task_id> {` and end with `}`.
9. End every task with halt.
10. `halt` must be the last statement inside the task block.
11. Do not add extra actions not explicitly required by the instruction.
12. If the instruction says "wait then read", the program must be exactly wait->read->halt
    after capabilities.

```

D.2 JSON System Prompt

Listing 4: JSON 生成 System Prompt

```

You generate JSON control programs for hardware control tasks.
Output only JSON. No explanation, no markdown fences.
The JSON object must have exactly three fields: "task" (string), "cap" (array of device names),
    "body" (array of operations).
Allowed operations (each with an "op" field):
{"op":"set","dev":"<d>","to":0|1} — set relay/actuator state
{"op":"read","dev":"<d>"} — read sensor/relay value
{"op":"wait","ms":<int>} — wait milliseconds
{"op":"readback","dev":"<d>","expect":0|1} — verify device state (must be last in retry body)
{"op":"retry","times":<int>,"do":[<ops>]} — retry body up to N times, body must end with
    readback
{"op":"repeat","times":<int>,"do":[<ops>]} — repeat body exactly N times unconditionally
{"op":"halt"} — stop execution, must be last in body
Rules: declare all used devices in "cap"; body must end with halt; retry body must end with
    readback.
IMPORTANT retry vs repeat: retry for "try/verify/ensure/confirm/read back" tasks; repeat for
    "repeat/loop/toggle/do N times" tasks.

```

D.3 Python System Prompt

Listing 5: Python 生成 System Prompt

```

You generate compact Python-like control snippets for hardware control tasks.
Output only Python code.
Use only direct imperative control statements that fully represent the task.

```

表 13: if/else + repeat 控制流生成实验 (tasks_v4, $n=15$, temp=0.0)

指标	数值	95% Wilson CI
IR validity rate	0.933	[0.698, 0.997]
Compile pass rate	0.933	[0.698, 0.997]
Task success rate	0.867	[0.641, 0.963]
Failed tasks	2 / 15	—

表 14: 闭环扩展生成实验 (tasks_v3_expanded, $n=96$, temp=0.0)

指标	数值	95% Wilson CI
IR validity rate	0.948	[0.886, 0.979]
Compile pass rate	0.948	[0.886, 0.979]
Task success rate	0.948	[0.886, 0.979]
Failed tasks	5 / 96	—
Primary failure code	MIR_PARSE_ERROR (5)	—

E 附录 C: 补充实验结果表

表 15: 失败案例错误类型分类

错误类型	113 任务集	控制流 (15 任务)	闭环扩展 (96 任务)	典
MIR_PARSE_ERROR	2	1	5	LLM 偶发
TASK_SIGNATURE_MISMATCH (基础 prompt)	0	1	41 [*]	基础 prompt 下编译通过但设
retry → repeat 混淆 (基础 prompt)	0	0	34 [*]	基础 prompt 下错用 repeat
[*] 基础 prompt (v2) 数据, 优化 prompt (v3) 下此项已清零。				

表 16: System prompt 缓存场景下的增量成本对比 (52 任务)

格式	缓存后增量成本 (output tokens)	相对 JSON
MIR	40.00	0.516×
JSON	77.54	1.000×
PYTHON	17.19	0.222×

表 17: 多模型横比: 113 确定性任务生成结果 (temperature=0.0)

模型	IR Valid	Compile	Task Success	95% CI	主要错误
llama3.1:8b	1.000	1.000	1.000	[0.968, 1.000]	—
qwen3:8b	0.956	0.956	0.903	[0.835, 0.946]	TASK_SIG (6) + PARSE (5)
deepseek-r1:8b	1.000	1.000	1.000	[0.968, 1.000]	—

表 18: 负基线对比: JSON + Schema + 外部压缩 vs M-IR + 编译器 (113 确定性任务, llama3.1:8b, temp=0.0)

指标	JSON + Schema + zlib	M-IR → M-bytecode
生成有效率	1.000 [0.967, 1.000]	1.000 [0.968, 1.000]
任务成功率	0.965 [0.913, 0.986]	1.000 [0.968, 1.000]
平均原始输出 (bytes)	156.4	—
平均紧凑输出 (bytes)	147.4	—
平均 zlib level 9 (bytes)	106.7	—
平均 CBOR (bytes)	105.2	—
平均 M-bytecode (bytes)	—	10.9
M vs zlib-JSON 压缩比	—	9.8×
M vs CBOR 压缩比	—	9.6×
失败主因	TASK_SIG_MISMATCH (4)	—
Direct Hex (同任务集)	0.000	—




图 3: MVM 运行时架构图。主路径包括加载、解码、静态检查、运行时守护与输出，任何守护失败均导向 Fault 状态。




图 4: 闭环验证的状态机模型。SET → ACK → READBACK → COMPARE。匹配时收敛，故障时进入 SAFE/FAULT，不匹配时 retry 回到 SET。

Fig.5 LLM to M-bytecode Generation and Repair Pipeline

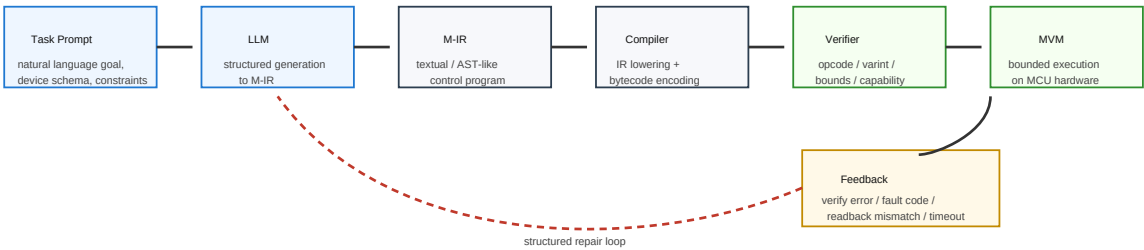


图 5: 完整的生成链路：LLM 输出 M-IR 文本后，经 parser、compiler、verifier 生成 M-bytecode，失败时进入 repair loop。




图 6: 压缩率图。E1 实验中 M-bytecode 与 JSON 的 payload 体积对比。




图 7: 安全机制消融分析。E2 正交消融实验的综合结果: (a) 各安全机制拦截的 fault 类型分布 (堆叠柱状图); (b) 各消融变体下的 UABR 与 fault rate 对比。两图共同说明 capability gating、validator 和 step-limit 各自构成独立的安全层, 移除任一均导致阻断率下降。




图 8: SCR 对比图。E4 实验中 M 路径与 JSON 路径的安全收敛率 (SCR) 对比。




图 9: SAFE 曲线。E5+ 实验中不同故障先验下的 SAFE 分流率曲线。




图 10: 生成与修复结果及 Token 成本对比。面板 (a) 展示了 113 任务上的生成链路与 repair loop 结果；当前确定性子集上的首轮 `parse` $\rightarrow$ `compile` $\rightarrow$ `verify` $\rightarrow$ `execute` 链路已经达到满通过，repair 主要用于修复极少数残余格式偏差。面板 (b) 展示了 52 个三方语义等价任务上的 token 与输出体积对比；M-IR 相对 JSON 更紧凑，但仍未达到极简 Python 片段的输出长度。